

Modelo Linear bayesiano

joseferson da silva barreto

.

Professor(a): Fenanda Clotilde

Projeto final Inferência bayesiana apresentado na
última aula da disciplina .

dezembro,07,2022

Sumário

- Objetivo
- Metodos
- Introdução
- Resultados
- Conclusão

.

Objetivo

O objetivo é apresentar de forma clara o que são os modelos lineares bayesianos, e verificar sua importância para análises estatísticas.

Método

Foi feito os tratamentos dos dados para buscar relações entre as variáveis, a limpeza dos dados foi feita no software Rstudio, utilizando a linguagem R para as demais análises. Para essa análise foi utilizado um banco de dados sobre os prejuízos causados as seguradoras pelos furacões nos Estados Unidos de 1954 a 1984.

Introdução

Os modelos Bayesianos são utilizados quando estamos buscando explicar o desconhecido através de distribuições de probabilidades de modo subjetivo, ou seja, a inferência Bayesiana é uma metodologia estatística baseada na definição de probabilidade como um grau de informação. Neste artigo veremos um modelo de poisson bayesiano generalizado.

Matematicamente o modelo Linear Generalizado de poisson é aplicado quando temos a ocorrência de eventos discretos ao longo de intervalos específicos, entretanto, para utilizar os modelos de poisson é necessário verificar se não tem excesso de zeros e se nossos dados não estão tão dispersos, além disso nossos dados tem que ser discretos.

- sem excesso de zeros e com dispersão: poisson com dispersão e binomial negativa sem/com dispersão

Os dados utilizados nesse artigo é de uma pesquisa feita em 2014 sobre os prejuízos causados as seguradoras pelos furacões que ocorre regularmente nos estados unidos, esse dataset é de 1954 a 1984.

Carregando o Banco de Dados

Para carregar nosso conjunto de dados vamos utilizar os comandos a baixo, nosso dataset utilizado nesse arquivo está disponível no github

```
library (readr)
urlfile="https://raw.githubusercontent.com/metodosexatos/mlgbayes/main/DatasetsES15/hurricanes.csv"
mydata<-read_csv2(url(urlfile)) # para csv no formato brasileiro use read_csv2#head(mydata)
```

Verificando os Histograma da Priori

A distribuição a priori de Poisson é definida de forma caso uma variável aleatória discreta Y tem uma distribuição de Poisson com parâmetro $\theta > 0$ se sua função de massa de probabilidade satisfaz:

$$f(y|\theta) : \frac{e^{-\theta}\theta^y}{y!}, \quad y = 0, 1, 2, \dots$$


Se Y tem um $\text{Poisson}(\theta)$ distribuição então

$$E(y) = \theta$$

$$\text{Var}(y) = \theta$$

Vamos observar a nossa distribuição apriori através do histograma gerado com o código abaixo:

```
#-----  
# Histograma da variável dependente:  
  
k <- round(1+3.3*log10(nrow(mydata)),0) # Número de classes: Regra de Sturges  
hist(mydata$loss, main = "Valores observados", xlab = "Loss", nclass = k, col = 5)
```



```
mean(mydata$loss)
```

```
## [1] 563.4545
```

Como temos poucas observações nós não conseguimos observar muito bem se ele segue a distribuição de poisson, sabemos que só temos informação sobre o conjunto dos naturais

Criação do Modelo

Para criação do modelo vamos utilizar o pacote **rstanarm** com a função `stan_glm` que criará nosso modelo

```
library(rstanarm)
```

```
model_poisson <- stan_glm(loss ~ hurr, data = mydata, family = poisson())
```

Para ver as informações sobre o modelo gerado vamos utilizar a função **summary**

```
summary(model_poisson)
```

```
##
## Model Info:
## function:      stan_glm
## family:        poisson [log]
## formula:       loss ~ hurr
## algorithm:     sampling
## sample:        4000 (posterior sample size)
## priors:        see help('prior_summary')
## observations:  33
## predictors:    2
##
## Estimates:
##           mean    sd   10%   50%   90%
## (Intercept) 6.0    0.0   6.0   6.0   6.0
## hurr         0.3    0.0   0.3   0.3   0.3
##
## Fit Diagnostics:
##           mean    sd   10%   50%   90%
## mean_PPD 563.4    5.9 556.0 563.4 571.1
##
## The mean_ppd is the sample average posterior predictive distribution of the outcome variable (for de
##
## MCMC diagnostics
##           mcse Rhat n_eff
## (Intercept) 0.0  1.0  1826
## hurr         0.0  1.0  2451
## mean_PPD     0.1  1.0  2447
## log-posterior 0.0  1.0  1504
##
## For each parameter, mcse is Monte Carlo standard error, n_eff is a crude measure of effective sample
```

Aqui temos algumas informações importantes sobre o modelo:

function: mostra a função utilizada para criação do modelo(`stan_glm`)

family: mostra a família de distribuição utilizada para geração do modelo e o respectivo lik de ligação, no nosso caso foi a poisson com o link(log)

formula: mostra a formula com as variáveis usadas no modelo

algorithm: mostra o método utilizado para criação do modelo, no nosso caso foi amostragem

sample: mostra o número de observações geradas na nossa posteriori, temos um total de 4000 observações geradas

observations: mostra o número de observações utilizadas para a geração do modelo

predictors: mostra o número de variáveis utilizadas para a criação do modelo

Ainda temos outras informações como média e desvio padrão dos estimadores e dos valores preditos, mas vamos focar na análise dos coeficientes

Analisando os Coeficientes

```
coeff <- round(exp(model_poisson$coefficients),2)
coeff
```

```
## (Intercept)      hurr
##      404.94      1.29
```

Podemos ver que o nosso intercepto é 404.91 e o $\beta_1 = 1.29$

considerando que o intercepto foi 404.91 isso representa que a perda esperada de início é de aproximadamente 400 dolares na média e o $\beta_1 = 1.29$ significa que a cada furacão que acontece por ano nós esperamos um acréscimo, uma perda de uma seguradora de 1.29, ou seja, essa é uma taxa associada a cada furacão a mais que vai ocorrer, por exemplo, se ocorrerem 3 furacões pegasse 1.29 e multiplica-se por 3 furacões

Histograma da Distribuição Posterior

Por definição se $Y \sim \text{Poisson}(\theta)$ a priori, logo Y a posteriori será de forma $Y \sim \text{Poisson}(\theta)$, ou seja,

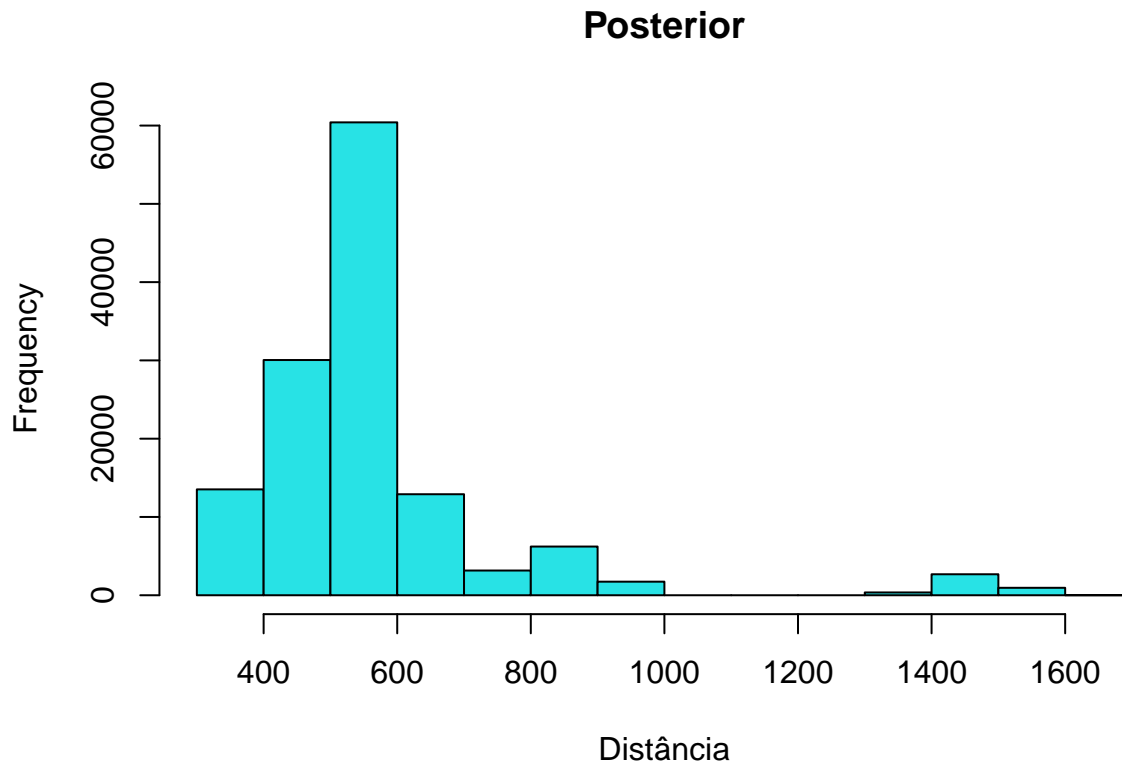
$$f(y|\theta) : \frac{e^{-\theta}\theta^y}{y!}, \quad y = 0, 1, 2, \dots$$

Se Y tem um $\text{Poisson}(\theta)$ distribuição então

$$E(y) = \theta$$

$$\text{Var}(y) = \theta$$

```
k <- round(1+3.3*log10(nrow(posterior_predict(model_poisson))),0) # Número de classes: Regra de Sturges
hist(posterior_predict(model_poisson), main = "Posterior", xlab = "Distância", nclass = k, col = 5)
```



Agora podemos observar um comportamento mais parecido com a poisson ,ela começa com um leve crescimento, ela continua até atingir o ponto máximo e depois começa a cair ,Vamos analisar o intervalo de credibilidade.

Intervalo de Credibilidade

```
exp(posterior_interval(model_poisson))
```

```
##                5%          95%
## (Intercept) 397.277445 412.252406
## hurr        1.281583   1.305576
```

segundo o intervalo de credibilidade é esperado que tenhamos por exemplo um acontecimento por ano por furacão uma perda por seguradora de 397 a 412 milhões de dólares.

Conclusão

Como podemos ver os modelos bayesianos vem sendo amplamente utilizados devido às suas vantagens e desenvolvimento de computadores, principalmente em cenários onde há Falta de métodos claros para incluir dados(conhecimentos) existentes e para lidar com incerteza nos métodos frequentistas. Demos uma breve introdução ao modelo de poisson bayesiano generalizado, que utilizamos para prever o impacto dos furacões a seguradoras, ou seja, o seu prejuízo econômico,registrando por ano um prejuízo entre 397 a 412 milhoes de dólares.

Referências

EFL Amaral, INÁCIO Magna - Modelos Bayesianos

Dogucu, Mine, Alicia Johnson e Miles Ott. 2022. Regras de Bayes! Uma Introdução à Modelagem Bayesiana Aplicada . 1ª ed. Boca Raton, Flórida: Chapman; Salão/CRC. <https://www.bayesrulesbook.com/> .

Kruschke, John. 2015. Fazendo análise de dados bayesiana: um tutorial com r, JAGS e Stan. 2ª ed. Imprensa Acadêmica. <https://sites.google.com/site/doingbayesiandataanalysis/> .

GELMAN, Andrew. Objections to Bayesian statistics. Bayesian Analysis, v. 3, n. 3, pp. 445–449, 2008.

Gelman, Andrew; Carlin, John B.; Stern, Hal S.; Dunson, David B.; Vehtari, Aki; Rubin, Donald B. Bayesian data analysis. 3rd ed. Chapman & Hall/CRC, Boca Raton, 2014.